



Luca Lontos  
21. September 2021

## Inhaltsverzeichnis

<b>1</b>	<b>Interpolation</b>	<b>3</b>
1.1	Polynominterpolation	3
1.1.1	Lagrange	3
1.1.2	Newton	3
1.1.3	Fehlerabschätzung	3
1.2	Spline-Interpolation	4
1.2.1	Linear	4
1.2.2	Kubisch	4
<b>2</b>	<b>Numerische Integration</b>	<b>6</b>
2.1	Newton-Cotes-Quadratur	6
2.1.1	geschlossen	6
2.1.2	offen	6
2.2	Summierte Newton-Cotes	7
<b>3</b>	<b>Numerische Behandlung von Anfangswertproblemen gewöhnlicher Differentialgleichungen</b>	<b>8</b>
3.1	Einführung	8
3.1.1	Verfahren	8
3.2	Steife Differentialgleichungen	9
3.2.1	Stabilitätsgebiete einiger Verfahren	10
<b>4</b>	<b>Lineare Gleichungssysteme</b>	<b>11</b>
4.1	Problemstellung	11
4.2	Gaußsche Eliminationsverfahren, Dreieckszerlegung einer Matrix	11
4.2.1	Lösung gestaffelter Gleichungssysteme	11
4.2.2	Gaußsches Eliminationsverfahren	11
4.2.3	Pivotstrategie	11
4.2.4	LR-Zerlegung	11
4.2.5	Matrizenklassen, die keine Pivotsuche erfordern	12
4.3	Das Cholesky Verfahren	12
4.4	Fehlerabschätzung und Rundungsfehlereinfluss	12
4.4.1	Fehlerabschätzung für gestörte Gleichungssysteme	12
<b>5</b>	<b>Nichtlineare Gleichungssysteme</b>	<b>13</b>
5.1	Einführung	13
5.2	Das Newton-Verfahren	13
5.2.1	Herleitung	13
5.2.2	Superlineare und quadratische lokale Konvergenz des Newton-Verfahrens	14
5.2.3	Globalisierung des Newton-Verfahrens	14
<b>6</b>	<b>Verfahren zur Eigenwert- und Eigenvektorberechnung</b>	<b>15</b>
6.1	Eigenwertprobleme	15
6.1.1	Grundlagen	15
6.1.2	Beispiele	15

6.1.3	Grundkonzepte numerischer Verfahren	15
6.1.4	Störungstheorie für Eigenwertprobleme	16
6.2	Die Vektoriteration	16
6.2.1	Definition und Eigenschaften der Vektoriteration	16
6.2.2	Die Vektoriteration nach v. Mises und Wielandt	17
6.3	Das QR-Verfahren	17
<b>7</b>	<b>Grundbegriffe der Statistik und Wahrscheinlichkeitstheorie</b>	<b>17</b>
7.1	Messreihen	17
7.2	Lage- und Streumaßzahlen	18
7.2.1	Lagemaßzahlen	18
7.2.2	Streuungsmaße	18
7.2.3	Zweidimensionale Messreihen	18
7.2.4	Regressionsgerade	19
7.3	Zufallsexperimente und Wahrscheinlichkeit	19
7.3.1	Zufallsexperimente	19
7.3.2	Wahrscheinlichkeit	19
7.3.3	Elementare Formeln der Kombinatorik	20
7.4	Bedingte Wahrscheinlichkeit, Unabhängigkeiten	20
7.4.1	Bedingte Wahrscheinlichkeit	20
7.4.2	Unabhängigkeit	20
7.5	Zufallsvariablen und Verteilungsfunktion	20
7.5.1	Beispiele für diskrete Verteilungen	21
7.5.2	Beispiele für Stetige Verteilungen	22
7.6	Erwartungswert und Varianz	22
7.6.1	Rechenregeln	23
7.7	Gesetz der großen Zahlen, zentraler Grenzwertsatz	24
7.7.1	Das schwache Gesetz der großen Zahlen	24
7.7.2	Zentraler Grenzwertsatz	24
7.8	Testverteilungen und Quantilapproximationen	24
7.8.1	Wichtige Anwendungsbeispiele	25
<b>8</b>	<b>Schätzverfahren und Konfidenzintervalle</b>	<b>26</b>
8.1	Grundlagen zu Schätzverfahren	26
8.2	Maximum-Likelihood-Schätzer	26
8.3	Konfidenzintervalle	27
8.3.1	Konstruktion von Konfidenzintervallen	27
<b>9</b>	<b>Tests bei Normalverteilungsannahmen</b>	<b>28</b>
9.1	Grundlagen	28
9.2	Wichtige Tests bei Normalverteilungsannahme	28
9.3	Verteilungstests	28

---

## 1 Interpolation

---

### 1.1 Polynominterpolation

---

$n$  = Anzahl Stützstellen - 1

#### 1.1.1 Lagrange

---

$$p_n(x) = \sum_{k=0}^n y_k L_{k,n}(x) \quad \text{mit} \quad L_{k,n}(x) = \prod_{\substack{j=0 \\ j \neq k}}^n \frac{x - x_j}{x_k - x_j}$$

Trick effiziente/ übersichtliche Berechnung

k/j	$x_1$	$x_2$	...	$x_n$	$L_{k,n}$
$x_1$	$\backslash$	$\frac{x - x_2}{x_1 - x_2}$	...	$\frac{x - x_n}{x_1 - x_n}$	$\prod$ diese Zeile
$x_2$	$\frac{x - x_1}{x_2 - x_1}$	$\backslash$	...	$\frac{x - x_n}{x_2 - x_n}$	$\prod$ diese Zeile
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
$x_n$	$\frac{x - x_1}{x_n - x_1}$	$\frac{x - x_2}{x_n - x_2}$	...	$\backslash$	$\prod$ diese Zeile

**Satz 1.1.1** es gibt genau ein Polynom  $p(x)$  vom Grad  $\leq n$ , das die interpolationsbedingungen erfüllt, nämlich  $p_n(x)$

#### 1.1.2 Newton

---

$$p_n(x) = \gamma_0 + \sum_{i=1}^n \gamma_i (x - x_0) \dots (x - x_{i-1}), \quad \gamma_i = f_{[x_0 \dots x_i]}$$
$$f_{[x_j, \dots, x_{j+k}]} = \frac{f_{[x_{j+1}, \dots, x_{j+k}]} - f_{[x_j, \dots, x_{j+k-1}]}}{x_{j+k} - x_j} = \frac{f_{\text{unten}} - f_{\text{oben}}}{x_{\text{unten}} - x_{\text{oben}}}$$

Die Oberste Zeile ab dem Strich sind dann die  $\gamma_i$

$$\begin{array}{c|l} x_0 & f_{[x_0]} = y_0 \searrow \\ & f_{[x_0, x_1]} \searrow \\ x_1 & f_{[x_1]} = y_1 \swarrow \quad f_{[x_0, x_1, x_2]} \\ & f_{[x_1, x_2]} \swarrow \\ x_2 & f_{[x_2]} = y_2 \nearrow \\ \vdots & \end{array}$$

---

#### 1.1.3 Fehlerabschätzung

---

**Satz 1.1.3** Voraussetzungen für max error Korollar:  $f$  ist  $n+1$  mal stetig diffbar

**Korollar 1.1.4** Wenn Satz 1.1.3 gilt:

**Äquidistant:**

$$\max_{x \in [a, b]} |f(x) - p_n(x)| \leq \max_{x \in [a, b]} \frac{|f^{(n+1)}(x)|}{(n+1)!} (b-a)^{n+1}$$

**Tschebyschev-Abszissen:**

$$\max_{x \in [a, b]} |f(x) - p_n(x)| \leq \max_{x \in [a, b]} \frac{|f^{(n+1)}(x)|}{(n+1)!} \left( \frac{b-a}{2} \right)^{n+1} 2^{-n}$$

**Inverse Interpolation:**

Sei  $f : [a, b] \rightarrow \mathbb{R}$  bijektiv. Sind dann alle  $(x_i, y_i), y_i = f(x_i)$  Stützpunkte von  $f$  dann sind  $(y_i, x_i)$  Stützpunkte für  $f^{-1}$  und eine Approximation kann durch Interpolation dieser gewonnen werden

---

## 1.2 Spline-Interpolation

---

**Definition 1.2.1** Eine Splinefunktion der Ordnung  $k$  zur Zerlegung  $\Delta$  ist eine Funktion  $s : [a, b] \rightarrow \mathbb{R}$  mit folgenden Eigenschaften:

- es gilt  $s \in C^{k-1}([a, b])$  (stetig diffbar)
- $s$  stimmt auf jedem Intervall  $[x_i, x_{i+1}]$

**Spline-Interpolation:**

Zu einer Zerlegung  $\Delta = \{x_i : a = x_0 < x_1 < \dots < x_n = b\}$  und werten  $y_i \in \mathbb{R}, i = 0, \dots, n$  bestimme  $s \in S_{\Delta, k}$  mit

$$s(x_i) = y_i, i = 0, \dots, n$$

---

### 1.2.1 Linear

---

$$s(x) = s_i(x) = \frac{x_{i+1} - x}{x_{i+1} - x_i} y_i + \frac{x - x_i}{x_{i+1} - x_i} y_{i+1} \quad \forall x \in [x_i, x_{i+1}]$$

mit Hilfsknoten  $x_{-1} < a$  und  $x_{n+1} > b$  gilt dann

$$\varphi_i(x) = \begin{cases} 0 & \text{falls } x \leq x_{i-1} \\ \frac{x - x_{i-1}}{x_i - x_{i-1}} & \text{falls } x \in [x_{i-1}, x_i] \\ \frac{x_{i+1} - x}{x_{i+1} - x_i} & \text{falls } x \in [x_i, x_{i+1}] \\ 0 & \text{falls } x > x_{i+1} \end{cases}$$
$$s(x) = \sum_{i=0}^n y_i \varphi_i(x), x \in [a, b]$$

**Satz 1.2.2** Zu einer Zerlegung  $\Delta = \{x_i : a = x_0 < x_1 < \dots < x_n = b\}$  von  $[a, b]$  und Werten  $y_i$  existiert genau ein interpolierender Spline

**Satz 1.2.3**

$$\max_{x \in [a, b]} |f(x) - s(x)| \leq \frac{1}{8} \max_{x \in [a, b]} |f''(x)| h_{\max}^2$$

---

### 1.2.2 Kubisch

---

$$s_i(x) = \frac{1}{6} \left( \frac{(x_{i+1} - x)^3}{x_{i+1} - x_i} M_i + \frac{(x - x_i)^3}{x_{i+1} - x_i} M_{i+1} \right) + c_i(x - x_i) + d_i$$

mit  $h_i = x_{i+1} - x_i$

$$d_i = y_i - \frac{h_i^2}{6} M_i \quad c_i = \frac{y_{i+1} - y_i}{h_i} - \frac{h_i}{6} (M_{i+1} - M_i)$$

**Natürliche Randbedingungen:**

$$\begin{aligned} M_0 &= M_n = 0 & b_0 &= b_n = 0 \\ \lambda_0 &= \lambda_n = 0 & \mu_0 &= \mu_n = 1 \end{aligned}$$

**Hermite Randbedingungen:**

$$\begin{aligned} b_0 &= \frac{y_1 - y_0}{h_0} - f'(a) & b_n &= f'(b) - \frac{y_n - y_{n-1}}{h_{n-1}} \\ \lambda_0 &= \frac{h_0}{3} & \mu_0 &= \frac{h_0}{3} & \lambda_n &= \frac{h_{n-1}}{6} & \mu_n &= \frac{h_{n-1}}{3} \end{aligned}$$
$$\begin{pmatrix} \frac{\mu_0}{6} & \frac{\lambda_0}{h_0+h_1} & \frac{h_1}{6} & & \\ \frac{h_0}{3} & \frac{h_1}{6} & \frac{h_1+h_2}{3} & \frac{h_2}{6} & \\ & \frac{h_1}{6} & \dots & \dots & \dots \\ & & & \lambda_n & \mu_n \end{pmatrix} \begin{pmatrix} M_0 \\ M_1 \\ M_2 \\ \dots \\ M_n \end{pmatrix} = \begin{pmatrix} b_0 \\ \frac{y_2-y_1}{h_1} - \frac{y_1-y_0}{h_0} \\ \frac{y_3-y_2}{h_2} - \frac{y_2-y_1}{h_1} \\ \dots \\ b_n \end{pmatrix}$$

---

**Satz 1.2.6** Fehler Natürlich

$$|f(x) - s(x)| \leq \frac{h_{max}}{h_{min}} \sup_{\xi \in [a,b]} |f^{(4)}(\xi)| h_{max}^4$$
$$|f^{(k)}(x) - s^{(k)}(x)| \leq \frac{2h_{max}}{h_{min}} \sup_{\xi \in [a,b]} |f^{(4)}(\xi)| h_{max}^{4-k}$$

**Satz 1.2.7** Fehler Hermit

$$|f(x) - s(x)| \leq \frac{5}{384} \sup_{\xi \in [a,b]} |f^{(4)}(\xi)| h_{max}^4$$
$$|f^{(k)}(x) - s^{(k)}(x)| \leq \frac{2h_{max}}{h_{min}} \sup_{\xi \in [a,b]} |f^{(4)}(\xi)| h_{max}^{4-k}$$

---

## 2 Numerische Integration

---

### 2.1 Newton-Cotes-Quadratur

---

#### 2.1.1 geschlossen

---

**Definition 2.1.1** Eine Integrationsformel  $J(f) = \sum_{i=0}^n \beta_i f(x_i)$  heißt exact vom Grad  $n$  falls sie alle Polynome bis mindestens vom Grad  $n$  exakt integriert

Allgemeiner Fehler

$$\int_a^b \|f(x) - p_n(x)\| dx \leq \frac{\|f^{(n+1)}(\xi)\|}{(n+1)!} (b-a)^{n+2}$$

Berechnung

$$x_i = a + ih$$

$$i = 0, \dots, n,$$

$$h = \frac{b-a}{n}$$

$$I_n(f) = h \sum_{i=0}^n \alpha_{i,n} f(x_i)$$

$n$	$h$	$\alpha_{i,n}$				$E_n(f)$	Name
1	$b-a$	$\frac{1}{2}$	$\frac{1}{2}$			$-\frac{f^{(2)}(\xi)}{12}h^3$	Trapezregel
2	$\frac{b-a}{2}$	$\frac{1}{3}$	$\frac{4}{3}$	$\frac{1}{3}$		$-\frac{f^{(4)}(\xi)}{90}h^5$	Simpson-Regel
3	$\frac{b-a}{3}$	$\frac{3}{8}$	$\frac{9}{8}$	$\frac{9}{8}$	$\frac{3}{8}$	$-\frac{3f^{(4)}(\xi)}{80}h^5$	3/8-Regel
4	$\frac{b-a}{4}$	$\frac{14}{45}$	$\frac{64}{45}$	$\frac{24}{45}$	$\frac{64}{45}$	$-\frac{8f^{(6)}(\xi)}{945}h^7$	Milne-Regel

---

#### 2.1.2 offen

---

Berechnung

$$x_i = a + ih$$

$$i = 1, \dots, n+1,$$

$$h = \frac{b-a}{n+2}$$

$$\tilde{I}_n(f) = h \sum_{i=1}^{n+1} \tilde{\alpha}_{i,n} f(x_i)$$

$n$	$h$	$\tilde{\alpha}_{i,n}$			$\tilde{E}_n(f)$	Name
0	$\frac{b-a}{2}$	2			$\frac{f^{(2)}(\xi)}{3} h^3$	Rechteckregel
1	$\frac{b-a}{3}$	$\frac{3}{2}$	$\frac{3}{2}$		$\frac{3f^{(2)}(\xi)}{4} h^3$	Rechteckregel
2	$\frac{b-a}{4}$	$\frac{8}{3}$	$-\frac{4}{3}$	$\frac{8}{3}$	$\frac{28f^{(4)}(\xi)}{90} h^5$	Rechteckregel

---

## 2.2 Summierte Newton-Cotes

---

Newton Cotes nur auf kleinen Intervallen präzise in kleinen Intervallen

Idee: Aufteilen in Teilintervalle

$$N = n \cdot m$$

$$x_i = a + ih$$

$$H = \frac{b-a}{m}$$

$$i = 0, \dots, N$$

$$h = \frac{b-a}{N}$$

### Summierte Trapezregel

(geschlossen,  $n = 1$ ,  $h = \frac{b-a}{m}$ )

$$S_N^{(1)}(f) = \frac{h}{2} \sum_{j=0}^{m-1} (f(x_j) + f(x_{j+1}))$$

$$\text{Fehler: } R_N^{(1)}(f) = -\frac{f''(\xi)}{12}(b-a)h^2$$

### Summierte Simpson-Regel

(geschlossen,  $n = 2$ ,  $h = \frac{b-a}{2m}$ )

$$S_N^{(2)}(f) = \frac{h}{3} \sum_{j=0}^{m-1} (f(x_{2j}) + 4f(x_{2j+1}) + f(x_{2j+2}))$$

$$\text{Fehler: } R_N^{(2)}(f) = -\frac{f^{(4)}(\xi)}{180}(b-a)h^4$$

### Summierte Rechteck-Regel

(offen,  $n = 0$ ,  $2m = N$ ,  $h = \frac{b-a}{N}$ )

$$\tilde{S}_N^{(0)} = 2h \sum_{j=1}^m f(x_{2j-1})$$

$$\text{Fehler: } \tilde{R}_N^{(0)}(f) = \frac{f''(\xi)}{6}(b-a)h^2$$

---

### 3 Numerische Behandlung von Anfangswertproblemen gewöhnlicher Differentialgleichungen

---

#### 3.1 Einführung

---

##### 3.1.1 Verfahren

---

Expliziter Euler

$$u_{j+1} := u_j + hf(t_j, u_j)$$

Impliziter Euler

$$u_{j+1} := u_j + hf(t_{j+1}, u_{j+1})$$

Implizite Trapezregel

$$u_{j+1} := u_j + \frac{h}{2}(f(t_j, u_j) + f(t_{j+1}, u_{j+1}))$$

Verfahren von Heun, erstes Runge-Kutta-Verfahren 2. Ordnung

$$u_{j+1} := u_j + \frac{h}{2}(f(t_j, u_j) + f(t_{j+1}, u_j + hf(t_j, u_j)))$$

kann man auch schreiben als:

$$u_{j+1} := u_j + \frac{h}{2}(k_1 + k_2)$$

mit  $k_1 = f(t_j, u_j)$ ,  $k_2 = f(t_{j+1}, u_j + hk_1)$

Modifizierter Euler, zweites Runge-Kutta-Verfahren 2. Ordnung

$$u_{j+1} = u_j + hk_2$$

mit  $k_1 = f(t_j, u_j)$ ,  $k_2 = f(t_j + \frac{h}{2}, u_j + \frac{h}{2}k_1)$

Klassisches Runge-Kutta-Verfahren 4. Ordnung (RK4)

$$u_{j+1} := u_j + \frac{h}{6}(k_1 + 2k_2 + 2k_3 + k_4)$$

$$k_1 := f(t_j, u_j)$$

$$k_2 := f(t_j + \frac{h}{2}, u_j + \frac{h}{2}k_1)$$

$$k_3 := f(t_j + \frac{h}{2}, u_j + \frac{h}{2}k_2)$$

$$k_4 := f(t_{j+1}, u_j + hk_3)$$

r-stufiges explizites Runge-Kutta-Verfahren

$$k_i(t, u, h) = k_i := f(t + \gamma_i h, u + h \sum_{j=1}^{i-1} \alpha_{ij} k_j), i = 1 \dots r$$

$$\phi(t, h; u) = \sum_{i=1}^r \beta_i k_i$$

Butcher – Schema

$\gamma_1$	0				
$\gamma_2$	$\alpha_{21}$	0			
$\gamma_3$	$\alpha_{31}$	$\alpha_{32}$	0		
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\ddots$	
$\gamma_r$	$\alpha_{r1}$	$\dots$	$\dots$	$\alpha_{r,r-1}$	0
	$\beta_1$	$\beta_2$	$\dots$	$\beta_{r-1}$	$\beta_r$



---

**Satz 3.1.7 Konsistenzordnungen  $p$** 

$p = 1$  falls

$$\sum_{i=1}^r \beta_i = 1$$

$p = 2$  falls zusätzlich

$$\sum_{i=1}^r \beta_i \gamma_i = \frac{1}{2}$$

$p = 3$  falls zusätzlich

$$\sum_{i=1}^r \beta_i \gamma_i^2 = \frac{1}{3}$$

$$\sum_{i,j=1}^r \beta_i \alpha_{ij} \gamma_j = \frac{1}{6}$$

$p = 4$  falls zusätzlich

$$\sum_{i=1}^r \beta_i \gamma_i^3 = \frac{1}{4},$$
$$\sum_{i,j=1}^r \beta_i \alpha_{ij} \gamma_j^2 = \frac{1}{12}$$

$$\sum_{i,j=1}^r \beta_i \gamma_i \alpha_{ij} \gamma_j = \frac{1}{8}$$
$$\sum_{i,j,k=1}^r \beta_i \alpha_{ij} \alpha_{jk} \gamma_k = \frac{1}{24}$$

---

**3.2 Steife Differentialgleichungen**

---

**Definition 3.2.2** ein Anfangswertproblemen

$$y'(t) = Ay(t) + c$$

$$y(a) = y_0$$

heißt steif, wenn die Realteile der Eigenwerte von  $A$  nichtpositiv sind und  $A$  Eigenwerte mit  $\operatorname{Re}(\lambda) \ll -1$  und Eigenwerte  $\lambda_i$  mit schwach negativen Realteil besitzt.

**Definition 3.2.3** Ein Verfahren heißt  $A$ -Stabil wenn seine Anwendung auf das Modellproblem

$$y' = \lambda,$$

$$y(0) = 1,$$

$$\text{mit } \lambda \in \mathbb{C},$$

$$\operatorname{Re}(\lambda) < 0$$

mit der Lösung

$$y(t) = e^{\lambda t}$$

für jede schrittweite  $h > 0$  eine Folge  $\{u_j\}_{j \in \mathbb{N}_0}$  produziert mit

$$|u_{j+1}| \leq |u_j|, \quad \forall j \geq 0$$

bei Einschrittverfahren gilt bei Anwendung auf das Modellproblem die Beziehung

$$u_{j+1} = R(q)u_j \text{ mit } q = \lambda h$$

**Definition 3.2.5** Mann nennt  $R$  die Stabilitätsfunktion des Einschrittverfahrens. Die Menge

$$S = \{q \in \mathbb{C} : |R(q)| \leq 1\}$$

heißt Stabilitätsgebiet des Einschrittverfahrens

**Definition 3.2.6** Ein Verfahren heißt  $L$ -Stabil, wenn es  $A$ -Stabil ist und die Stabilitätsfunktion zudem erfüllt

$$\lim_{q \rightarrow -\infty} R(q) = 0$$

---

### 3.2.1 Stabilitätsgebiete einiger Verfahren

---

#### Expliziter Euler

$$\begin{aligned}u_{j+1} &= (1 + \lambda h)u_j \\ R(q) &= 1 + q \\ S &= \{q \in \mathbb{C} : |1 + q| \geq 1\}\end{aligned}$$

Nicht A-Stabil (gilt für alle Expliziter RKs)

#### Impliziter Euler

$$\begin{aligned}u_{j+1} &= \frac{1}{1 - \lambda h}u_j \\ R(q) &= \frac{1}{1 - q}; q \neq 1 \\ S &= \{q \in \mathbb{C} : |1 + q| \geq 1\} \supset \{q \in \mathbb{C} : \operatorname{Re}(q) < 0\}\end{aligned}$$

A und L Stabil

#### Implizite Trapezregel

$$\begin{aligned}u_{j+1} &= \frac{1 + \lambda h/2}{1 - \lambda h/2}u_j \\ R(q) &= \frac{1 + q/2}{1 - q/2}; q \neq 2 \\ S &= \{q \in \mathbb{C} : \operatorname{Re}(q) \leq 0\}\end{aligned}$$

A aber nicht L Stabil

#### Implizite Runge-Kutta-Verfahren

$$k_i = k_i(t, u, h) := f(t + \gamma_i h, u + h \sum_{l=1}^r \alpha_{il} k_l), \quad i = 1, \dots, r$$

$$\phi(t, h; u) = \sum_{i=1}^r \beta_i k_i$$

#### Butcher-Schema

$\gamma_1$	$\alpha_{11}$	$\dots$	$\dots$	$\alpha_{1,r-1}$	$\alpha_{1,r}$
$\gamma_2$	$\alpha_{21}$	$\dots$	$\dots$	$\alpha_{2,r-1}$	$\alpha_{2,r}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
$\gamma_r$	$\alpha_{r1}$	$\dots$	$\dots$	$\alpha_{r,r-1}$	$\alpha_{r,r}$
	$\beta_1$	$\beta_2$	$\dots$	$\beta_{r-1}$	$\beta_r$

$$u_j + 1 = (1 + q\beta^T(I - qA)^{-1}\mathbf{1})u_j$$

$$R(q) = 1 + q\beta^T(I - qA)^{-1}\mathbf{1} = \frac{\det(I - qA + q\mathbf{1}\beta^T)}{\det(I - qA)}$$

---

## 4 Lineare Gleichungssysteme

---

### 4.1 Problemstellung

---

Lineares Gleichungssystem: Gesucht ist eine Lösung  $x$  von

$$Ax = b$$

mit

$$A = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \dots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{pmatrix} \quad b = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{pmatrix} \quad x = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}$$

**Definition 4.1.1** Das LGS hat eine Lösung g.d.w.

$$\text{rang}(a) = \text{rang}(A, b)$$

---

### 4.2 Gaußsche Eliminationsverfahren, Dreieckszerlegung einer Matrix

---

#### 4.2.1 Lösung gestaffelter Gleichungssysteme

---

Subsection Damit Nummerierung stimmt

---

#### 4.2.2 Gaußsches Eliminationsverfahren

---

1. Wähle ein Pivotelement  $a_{rk}^{(k)} \neq 0, k \leq r \leq n$  vertausche Zeile  $k$  und  $r \rightsquigarrow (\tilde{A}^{(k)}, \tilde{b}^{(k)})$
2. Für  $i = k + 1, \dots, n$ : Subtrahiere das  $l_{ik}$ -fache mit

$$l_{ik} = \frac{\tilde{a}_{ik}^{(k)}}{\tilde{a}_{kk}^{(k)}}$$

der  $k$ -ten Gleichung von der  $i$ -ten Gleichung

---

#### 4.2.3 Pivotstrategie

---

- Spaltenpivot: wähle  $k \leq r \leq n$  mit

$$|a_{rk}^{(k)}| = \max_{k \leq i \leq n} |a_{ik}^{(k)}|$$

- Vollständige Pivotsuche: Bestimme  $k \leq r \leq n, k \leq s \leq n$  mit

$$|a_{rs}^{(k)}| = \max_{k \leq i, j \leq n} |a_{ij}^{(k)}|$$

---

#### 4.2.4 LR-Zerlegung

---

Finden einer Zerlegung von  $A$  der Form

$$LR = PA(Q)$$

Gaußsche Eliminationsverfahren liefert dies "gratis" mit

$$R = A^{(n)} \quad c = b^{(n)} \quad L = I + L^{(n)}$$

um  $P$  zu erhalten fängt man mit  $I$  an und tauscht die Zeilen jedes mal wenn man in  $A$  auch die Zeilen tauscht,  $Q$  das selbe nur mit Spalten (nur bei Vollständige Pivotsuche)

nachdem Zerlegung gefunden kann einfach  $Ax = \tilde{b}$  gelöst werden

- Löse  $Lz = P\tilde{b}$
- Löse  $Ry = z$
- Lösung:  $x = Qy$

---

#### 4.2.5 Matrizenklassen, die keine Pivotsuche erfordern

---

- $A = A^T$  ist symmetrisch positiv definit, also

$$x^T A x > 0 \forall x \in \mathbb{R} \setminus \{0\}$$

- $A$  ist strikt diagonaldominant, d.h.,

$$|a_{ii}| > \sum_{j=1, j \neq i}^n |a_{ij}|, i = 1, \dots, n$$

- $A$  ist M-Matrix, d.h. es gilt

$$a_{ii} > 0, i = 1, \dots, n$$

$$a_{ij} \leq 0, i \neq j$$

$$D^{-1}(A - D) \text{ hat lauter Eigenwerte vom Betrag } < 1, D = \text{diag}(a_{11}, \dots, a_{nn})$$

---

#### 4.3 Das Cholesky Verfahren

---

**Definition 4.3.1** eine reelle Matrix heißt positiv definit falls

$$A = A^T, \quad x^T A x > 0 \quad \forall x \in \mathbb{R}^n \setminus \{0\}$$

positiv semidefinit falls

$$A = A^T, \quad x^T A x \geq 0 \quad \forall x \in \mathbb{R}^n \setminus \{0\}$$

**Satz 4.3.2** Es sei  $A$  positiv definit, Dann gibt es genau eine untere Dreiecksmatrix  $L$  mit positiven Diagonaleinträgen  $l_{ii} > 0$ , so das

$$LL^T = A \text{ (Cholesky-Zerlegung)}$$

Ferner besitzt  $A$  eine eindeutige Dreieckszerlegung

$$\tilde{L}\tilde{R} = A,$$

wobei  $\tilde{L} = LD^{-1}$ ,  $\tilde{R} = DL^T$

**Satz 4.3.3** Cholesky-Verfahren zur Berechnung der Zerlegung  $LL^T = A$

Für  $j = 1, \dots, n$

$$l_{jj} = \sqrt{a_{jj} - \sum_{k=1}^{j-1} l_{jk}^2}$$

Falls Wurzel nicht existiert, STOPP,  $A$  nicht definit

Für  $i = j + 1, \dots, n$ :

$$l_{ij} = \frac{a_{ij} - \sum_{k=1}^{j-1} l_{ik} l_{jk}}{l_{jj}}$$

---

#### 4.4 Fehlerabschätzung und Rundungsfehlereinfluss

---

---

##### 4.4.1 Fehlerabschätzung für gestörte Gleichungssysteme

---

**Definition 4.4.1** Eine Vektornorm auf  $\mathbb{R}^n$  ist eine Abbildung  $x \in \mathbb{R}^n \mapsto \|x\| \in [0, \infty[$  mit den Eigenschaften

- $\|x\| = 0$  nur für  $x = 0$
- $\|ax\| = |a| \|x\|$  für alle  $a \in \mathbb{R}$  und alle  $x \in \mathbb{R}^n$
- $\|x + y\| \leq \|x\| + \|y\|$  für alle  $x, y \in \mathbb{R}^n$  (Dreiecksungleichung)

**Definition 4.4.2** Eine Vektornorm induziert eine Matrixnorm, diese haben die Eigenschaften

- a)  $\|A\| = 0$  nur für  $A = 0$
- b)  $\|aA\| = |a| \|A\|$  für alle  $a \in \mathbb{R}$  und alle  $A \in \mathbb{R}^{n \times n}$
- c)  $\|A + B\| \leq \|A\| + \|B\|$  für alle  $A, B \in \mathbb{R}^{n \times n}$  (Dreiecksungleichung)
- d)  $\|Ax\| \leq \|A\| \|x\|$  für alle  $x \in \mathbb{R}^n$  und alle  $A \in \mathbb{R}^{n \times n}$  (Verträglichkeitsbedingung)
- e)  $\|AB\| \leq \|A\| \|B\|$  für alle  $A, B \in \mathbb{R}^{n \times n}$  (Submultiplikativität)

Beispiele hierfür sind:

$\ x\ _2 = \sqrt{x^T x}$	induziert	$\ A\ _2 = \sqrt{\lambda_{\max}(A^T A)}$	
$\ x\ _1 = \sum_{i=1}^n  x_i $	induziert	$\ A\ _1 = \max_{j=1, \dots, n} \sum_{i=1}^n  a_{ij} $	(Spaltensummennorm)
$\ x\ _\infty = \max_{i=1, \dots, n}  x_i $	induziert	$\ A\ _\infty = \max_{i=1, \dots, n} \sum_{j=1}^n  a_{ij} $	(Zeilensummennorm)

**Definition 4.4.3** Sei  $A \in \mathbb{R}^{n \times n}$  invertierbar und sein  $\|\cdot\|$  eine induzierte Matrixnorm. Dann heißt die Zahl  $\text{cond}(A) = \|A\| \|A^{-1}\|$  die Konditionszahl von  $A$  bezüglich der Matrixnorm

**Satz 4.4.4** (Störeinfluss von Matrix und rechter Seite). Sei  $A \in \mathbb{R}^{n \times n}$  invertierbar,  $b, \Delta b \in \mathbb{R}^n, b \neq 0$  und  $\Delta A \in \mathbb{R}^{n \times n}$  mit  $\|\Delta A\| < 1/\|A^{-1}\|$  mit einer beliebigen durch eine Norm  $\|\cdot\|$  auf  $\mathbb{R}^n$  induzierten Matrixnorm  $\|\cdot\|$ . Ist  $x$  die Lösung von

$$Ax = b$$

und  $\tilde{x}$  die Lösung von

$$(A + \Delta A)\tilde{x} = b + \Delta b$$

dann gilt

$$\frac{\|\tilde{x} - x\|}{\|x\|} \leq \frac{\text{cond}(A)}{1 - \text{cond}(A)\|\Delta A\|/\|A\|} \left( \frac{\|\Delta A\|}{\|A\|} + \frac{\|\Delta b\|}{\|b\|} \right)$$

## 5 Nichtlineare Gleichungssysteme

### 5.1 Einführung

### 5.2 Das Newton-Verfahren

#### 5.2.1 Herleitung

**Satz 5.2.1**

$$\begin{aligned} x_{k+1} &= x_k - J_f(x_k)^{-1} F(x_k) \\ x_{k+1} &= x_k + s_k \\ s_k &\text{ Lösung von } J_F(x_k) s_k = -F(x_k) \end{aligned}$$

**Satz 5.2.2** Algo für Lokales Newton-Verfahren

1. Falls  $F(x_k) = 0$  STOPP mit Ergebnis  $x_k$
2. Berechne  $s_k$
3.  $x_{k+1} = x_k + s_k$

---

### 5.2.2 Superlineare und quadratische lokale Konvergenz des Newton-Verfahrens

---

**Satz 5.2.3** (Schnelle Lokale Konvergenz des Newton-Verfahrens) Sei  $F$  stetig diffbar und sei  $\tilde{x} \in \mathbb{R}$  ein Punkt mit  $F(\tilde{x}) = 0$  und  $F'(\tilde{x})$  nichtsingulär. Dann gibt es  $\delta > 0$ , so dass folgende Aussagen gelten:

i)  $\tilde{x}$  ist die einzige Nullstelle in der  $\delta$ -Kugel

$$B_\delta(\tilde{x}) := \{x \in \mathbb{R}^n : \|x - \tilde{x}\|_2 < \delta\}$$

ii) Für alle  $x_0 \in B_\delta(\tilde{x})$  Terminiert der Algorithmus 5.2.2 entweder mit  $x_k = \tilde{x}$  oder erzeugt eine Folge  $(x_k) \subset B_\delta(\tilde{x})$ , die superlinear gegen  $\tilde{x}$  konvergiert d. h.

$$\lim_{k \rightarrow \infty} x_k = \tilde{x} \quad \text{wobei} \quad \|x_{k+1} - \tilde{x}\|_2 \leq v_k \|x_k - \tilde{x}\|_2$$

mit einer Nullfolge  $v_k \searrow 0$

iii) ist  $F'$  Lipschitz-stetig auf  $B_\delta(\tilde{x})$  mit Konstante  $L$  dann konvergiert  $(x_k)$  sogar quadratisch gegen  $\tilde{x}$ , d.h.

$$\lim_{k \rightarrow \infty} x_k = \tilde{x} \quad \text{wobei} \quad \|x_{k+1} - \tilde{x}\|_2 \leq C \|x_k - \tilde{x}\|_2^2$$

wobei für  $\delta > 0$  klein genug  $C = L \|F'(\tilde{x})^{-1}\|_2$  gewählt werden kann. Automatisch wenn zwei mal diffbar in  $B$

---

### 5.2.3 Globalisierung des Newton-Verfahrens

---

**schrittweisenwahl nach Armijo:**

sei  $\delta \in ]0, \frac{1}{2}[$  (z.B.  $10^{-3}$ ) fest gegeben. Wähle das Größte  $\sigma_k \in \{1, \frac{1}{2}, \frac{1}{4}, \dots\}$  mit

$$\|F(x_k + \sigma_k s_k)\|_2^2 \leq \|F(x_k)\|_2^2 - 2\delta\sigma_k \|F(x_k)\|_2^2$$

**Satz 5.2.4** Algo für das Globalisierte Newton-Verfahren:

1. Falls  $F(x_k) = 0$  STOPP mit Ergebnis  $x_k$
2. Berechne  $s_k$
3. Bestimme  $\sigma_k$  nach Armijo
4.  $x_{k+1} = x_k + \sigma_k s_k$

---

## 6 Verfahren zur Eigenwert- und Eigenvektorberechnung

---

### 6.1 Eigenwertprobleme

---

#### 6.1.1 Grundlagen

---

**Definition 6.1.1** Eine Zahl  $\lambda \in \mathbb{C}$  heißt Eigenwert einer Matrix  $A \in \mathbb{C}^{n \times n}$ , wenn es einen Vektor  $x \in \mathbb{C}^n$  gibt mit

$$Ax = \lambda x$$

Jedes solcher Vektor  $x \in \mathbb{C}^n$  heißt (Rechts-)Eigenvektor zum Eigenwert  $\lambda$ . Die Menge  $\sigma(A)$  aller Eigenwerte von  $A$  heißt Spektrum von  $A$ . Der Unterraum

$$\text{Eig}_A(\lambda) := \{x \in \mathbb{C}^n : (A - \lambda I)x = 0\}$$

Ist der Eigenraum von  $A$  zum Eigenwert  $\lambda$ . Seine Dimension

$$\gamma(\lambda) := \dim \text{Eig}_A(\lambda) = n - \text{Rang}(A - \lambda I)$$

ist die geometrische Vielfachheit von  $\lambda$  und gibt die Maximal linear unabhängigen Eigenvektoren zu  $\lambda$  an.  
 $\lambda$  ist EW zu  $A$  gdw:

$$\chi(\lambda) := \det(A - \lambda I) = 0$$

also wenn  $\lambda$  Nullstelle des charakteristischen Polynoms  $\chi(\mu)$  von  $A$  ist

$$\begin{aligned}\chi(\mu) &= (-1)^n \mu^n + (-1)^{n-1} \mu^{n-1} \text{Spur}(A) + \dots + \det(A) \\ &= (-1)^n (\mu - \lambda_1)^{\nu_1} \dots (\mu - \lambda_k)^{\nu_k}\end{aligned}$$

man nennt  $\nu(\lambda_i) = \nu_i$  die algebraische Vielfachheit von  $\lambda_i$ . Es gilt:

$$\gamma(\lambda_i) \leq \nu(\lambda_i)$$

**Definition 6.1.2** Sei  $A \in \mathbb{C}^{n \times n}$  beliebig:

- a) Ist  $\lambda$  EW von  $A$ , so ist  $\lambda$  EW von  $A^T$  und  $\bar{\lambda}$  EW von  $A^H := \bar{A}^T$
- b) für jede nichtsinguläre Matrix  $T \in \mathbb{C}^{n \times n}$  hat die zu  $A$  ähnliche Matrix  $B := T^{-1}AT$ , das selbe charakteristische Polynom und die selben Eigenwerte wie  $A$ . Ist  $x$  Eigenvektor von  $A$ , so ist  $y := T^{-1}x$  Eigenvektor von  $B$
- c) Ist  $A$  hermitisch also  $A^H = A$ , dann hat  $A$  lauter reelle Eigenwerte. Ist  $A$  unitär, also  $A^H = A^{-1}$ , so gilt  $|\lambda| = 1$  für jeden Eigenwert  $\lambda$

---

#### 6.1.2 Beispiele

---

damit Nummerierung passt

---

#### 6.1.3 Grundkonzepte numerischer Verfahren

---

**Vektoriteration**

$$x^{(k+1)} = \frac{Bx^{(k)}}{\|Bx^{(k)}\|}, \text{ mit } k = 0, 1, \dots$$

**Ähnlichkeitstransformation auf einfachere Gestalt** Nach Definition 6.1.2 bleiben die Eigenwerte einer Matrix  $A$  bei einer Ähnlichkeitstransformation erhalten. Daher liegt nahe  $A$  durch

$$A^{(0)} := A \rightarrow A^{(1)} \rightarrow \dots \rightarrow A^{(k+1)} = T_k^{-1} A^{(k)} T_k$$

in eine einfachere Form zu überführen

---

### 6.1.4 Störungstheorie für Eigenwertprobleme

---

**Satz 6.1.3** Bezeichnet  $\lambda_i(A)$ ,  $i = 1, \dots, n$  die angeordneten EWs einer Matrix  $A \in \mathbb{C}^{n \times n}$ . Dann sind die Abbildungen

$$A \in \mathbb{C}^{n \times n} \mapsto \lambda_i(A)$$

stetig. Eigenwerte hängen also stetig von der Matrix ab

**Satz 6.1.4** Es sei  $A = (a_{ij}) \in \mathbb{C}^{n \times n}$  beliebig

a)

$$\sigma(A) \subset \bigcup_{i=1}^n K_i$$
$$K_i = \left\{ \mu \in \mathbb{C} \mid |\mu - a_{ii}| \leq \sum_{j=1, j \neq i}^n |a_{ij}| (\text{zeilensumme ohne diag}) \right\}$$

b) ist die Vereinigung  $G_1$  von  $k$  Greshgorin-kreisen disjunkt von der Vereinigung  $G_2$  der restlichen  $n-k$  Kreise, dann enthält  $G_1$  genau  $k$  EWs und  $G_2$  genau  $n-k$  EWs von  $A$

**Satz 6.1.5** (Bauer/Fike). Es sei  $A \in \mathbb{C}^{n \times n}$  diagonalisierbar, also

$$T^{-1}AT = \text{diag}(\lambda_1, \dots, \lambda_n) =: D$$

Dann gilt für jede Matrix  $\Delta A \in \mathbb{C}^{n \times n}$

$$\forall \mu \in \sigma(A + \Delta A) : \min_{i=1, \dots, n} |\mu - \lambda_i| \leq \text{cond}_2(T) \|\Delta A\|_2$$

mit  $\text{cond}_2(T) := \|T\|_2 \|T^{-1}\|_2$ ;  $\text{cond}_2(T) := 1$  für  $A$  hermitisch

---

## 6.2 Die Vektoriteration

---

### 6.2.1 Definition und Eigenschaften der Vektoriteration

---

**Definition 6.2.1** für eine Matrix  $B \in \mathbb{C}^{n \times n}$  ist die Vektoriteration gegeben durch

$$z^{(k+1)} = \frac{1}{\|Bz^{(k)}\|} Bz^{(k)}, \text{ mit } k = 0, 1, \dots$$

mit einem Startvektor  $z^{(0)} \in \mathbb{C}^n \setminus \{0\}$

mit geeigneter Wahl von  $B$  erhält man so Näherungen an einen Eigenvektor zu  $\lambda$ . Eine Eigenwertnäherung für  $\lambda$  erhält man dann durch den **Rayleighquotienten**

$$R(z^{(k)}, B) = \frac{(z^{(k)})^H B z^{(k)}}{(z^{(k)})^H z^{(k)}}$$

**Satz 6.2.2** Es sei  $B \in \mathbb{C}^{n \times n}$  diagonalisierbar mit EWs  $\lambda_1, \dots, \lambda_n$

$$\lambda_1, \dots, \lambda_r, |\lambda_r| > |\lambda_{r+1}| \geq \dots \geq |\lambda_n| \quad (1)$$

mit  $r < n$ . Falls der Startvektor  $z^{(0)}$  einen Anteil in  $\text{Eig}_B(\lambda_1)$  besitzt, gilt für die Vektoriteration

$$R(z^{(k)}, B) = \frac{(z^{(k)})^H B z^{(k)}}{(z^{(k)})^H z^{(k)}} = \lambda_1 + O(q^k) \text{ für } k \rightarrow \infty, q = \frac{\lambda_{r+1}}{\lambda_1} < 1$$

zudem gilt

$$z^{(k)} = \frac{\lambda_1^k}{|\lambda_1|^k} \frac{x_1}{\|x_1\|} + O(q^k), k \geq 1$$

wobei  $x_1$  den Anteil von  $z^{(0)}$  in  $\text{Eig}_B(\lambda_1)$  bezeichnet



---

### 6.2.2 Die Vektoriteration nach v. Mises und Wielandt

---

Sei  $A \in \mathbb{C}^{n \times n}$  gegeben

#### Einfache Vektoriteration nach von Mises

Erhält man durch die Wahl von  $B = A - \mu I$  Inverse Vektoriteration von Wielandt für  $\mu \neq \lambda_j$  hat die Matrix  $B = (A - \mu I)^{-1}$  die EWs

$$\mu_i = \frac{1}{\lambda_i - \mu}$$

$$z^{(k+1)} = \frac{\hat{z}^{(k+1)}}{\|\hat{z}^{(k+1)}\|} \text{ mit } \hat{z}^{(k+1)} = (A - \mu I)^{-1} z^{(k)}$$

Lösbar durch

$$(A - \mu I) \hat{z}^{(k+1)} = z^{(k)}$$

hat im Falle

$$q := \max_{1 \leq i \leq n, \lambda_i \neq \lambda_j} \frac{|\lambda_j - \mu|}{|\lambda_i - \mu|} < 1$$

die Konvergenzeigenschaften

$$R(z^{(k)}, (A - \mu I)^{-1}) = \frac{(z^{(k)})^H \hat{z}^{(k+1)}}{(z^{(k)})^H z^{(k)}} = \frac{1}{\lambda_i - \mu} + O(q^k)$$
$$z^{(k)} = \frac{|\lambda_j - \mu|^k}{(\lambda_j - \mu)^k \|x_j\|} x_j + O(q^k)$$

wobei  $x_j$  den Anteil von  $z^{(0)}$  in  $\text{Eig}_A(\lambda_j) = \text{Eig}_{(A - \mu I)^{-1}}(1/(\lambda_j - \mu))$ . Ist  $A$  dabei hermitisch, so erfüllt der Rayleigh-Quotient

$$R(z^{(k)}, (A - \mu I)^{-1}) = \frac{(z^{(k)})^H \hat{z}^{(k+1)}}{(z^{(k)})^H z^{(k)}} = \frac{1}{\lambda_i - \mu} + O(q^{2k})$$

---

### 6.3 Das QR-Verfahren

---

#### Definition 6.3.1 Algorithmus QR-Verfahren

Sei  $A \in \mathbb{C}^{n \times n}$  eine gegebene Matrix

- Setze  $A^{(1)} := A$
- für  $l = 1, 2, \dots$ : Berechne

$$A^{(l)} =: Q_l R_l, \quad Q \in \mathbb{C}^{n \times n} \text{ unitär} \quad R_l \in \mathbb{C}^{n \times n} \text{ obere Dreiecksmatrix,}$$
$$A^{(l+1)} := R_l Q_l$$

---

## 7 Grundbegriffe der Statistik und Wahrscheinlichkeitstheorie

---

### 7.1 Messreihen

---

- quantitativ diskret: Merkmale sind ganze Zahlen
- quantitativ stetig: Die Merkmale sind reelle Zahlen

**Definition 7.1.1** Zu  $x_1, x_2, \dots, x_n$  ist  $(x_{(1)}, x_{(2)}, \dots, x_{(n)})$  die Geordnete Messreihe mit  $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$

Die Empirische Verteilungsfunktion hierzu ist

$$F(z; x_1, x_2, \dots, x_n) = F(z) = \frac{\text{Zahl der } x_i \text{ mit } x_i \leq z}{n}$$

mit  $r-1$  Zahlen  $a_1 < a_2 < \dots < a_{r-1}$  entsteht eine Unterteilung in  $r$  Klassen.

$$\mathbb{R} = ]-\infty, a_1] \cup ]a_1, a_2] \cup \dots \cup ]a_{r-2}, a_{r-1}] \cup ]a_{r-1}, \infty[$$

Man erhält die relativen Klassenhäufigkeiten für diese durch

$$F(a_1), F(a_2) - F(a_1), \dots, F(a_{r-1}) - F(a_{r-2}), 1 - F(a_{r-1})$$

Für Histogramm wähle  $a_0 < \min(a_1, x_{(1)})$ ,  $a_r > \max(a_{r-1}, x_{(n)})$ . Für jede Klassenhäufigkeit: Teile durch Klassenbreite und zeichne in Diagramm

---

## 7.2 Lage- und Streumaßzahlen

---

### 7.2.1 Lagemaßzahlen

---

Arithmetisches Mittel:

$$\bar{x} = \frac{1}{n}(x_1 + x_2 + \dots + x_n)$$

Median:

$$\tilde{x} = \begin{cases} x_{(\frac{n}{2})} & n \text{ wenn gerade} \\ x_{(\frac{n+1}{2})} & n \text{ wenn ungerade} \end{cases} \quad (2)$$

p-Quantil ( $0 < p < 1$ ):

$$x_p = \begin{cases} x_{(np)} & n \text{ wenn np ganzzahlig} \\ x_{(\lfloor np \rfloor + 1)} & n \text{ wenn np nicht ganzzahlig} \end{cases} \quad (3)$$

$\alpha$  gestutztes Mittel ( $0 < \alpha < 0.5$ ):

$$\bar{x}_\alpha = \frac{1}{n - 2k}(x_{(k+1)} + \dots + x_{(n-k)}), k = \lfloor n\alpha \rfloor$$

---

### 7.2.2 Streuungsmaße

---

Empirische Varianz oder empirische Stichprobenvarianz:

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Empirische Streuung:

$$s = \sqrt{s^2} \dots \text{duhhhhh}$$

Spannweite:

$$v = x_{(n)} - x_{(1)}$$

Quartilabstand:

$$q = x_{0.75} - x_{0.25}$$

---

### 7.2.3 Zweidimensionale Messreihen

---

Arithmetisches Mittel:

$$\bar{x} = \frac{1}{n}(x_1 + x_2 + \dots + x_n)$$

$$\bar{y} = \frac{1}{n}(y_1 + y_2 + \dots + y_n)$$

Empirische Varianz:

$$s_x^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

$$s_y^2 = \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2$$

Empirische Streuung:

$$s_x = \sqrt{s_x^2}$$

$$s_y = \sqrt{s_y^2}$$

Empirische Kovarianz

$$s_{xy} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

Empirischer Korrelationskoeffizient

$$r_{xy} = \frac{s_{xy}}{s_x s_y}$$

---

## 7.2.4 Regressionsgerade

---

$$y = ax + b$$

$$a = \frac{s_{xy}}{s_x^2}$$

$$b = \bar{y} - a\bar{x}$$

### Residuen

$$r_i = y_i - ax_i - b, i = 1, \dots, n$$

### Residuenquadrat

$$\sum_{i=1}^n r_i^2 = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

- Für  $r_{xy} > 0$  streng monoton fallende Gerade
- Für  $r_{xy} < 0$  streng monoton steigende Gerade
- Für  $r_{xy} = 0$  horizontale Gerade

---

## 7.3 Zufallsexperimente und Wahrscheinlichkeit

---

### 7.3.1 Zufallsexperimente

---

**Definition 7.3.1**  $\Omega$  heißt Ergebnismenge, seine Elemente  $\omega$  Ergebnisse. Teilmengen  $A \subseteq \Omega$  heißen Ereignisse. Ein Ereignis  $A \subseteq \Omega$  tritt ein, falls ein Ergebnis  $\omega \in A$  beobachtet wird.

**Definition 7.3.3** • Das aus zwei Ereignissen  $A$  und  $B$  zusammengesetzte Ereignis  $A \cup B$  tritt ein, falls ein Ergebnis  $\omega : \omega \in A \vee \omega \in B$  beobachtet wird

- Das Ereignis  $A \cap B$  tritt ein, falls ein Ergebnis  $\omega : \omega \in A \wedge \omega \in B$  beobachtet wird
- $A^c = \Omega \setminus A$  heißt zu  $A$  komplementäres Ereignis
- Zwei Ereignisse  $A$  und  $B$  heißen unvereinbar, falls  $A \cap B = \emptyset$
- $\emptyset$  heißt unmögliches Ereignis und  $\Omega$  sicheres Ereignis
- die einelementigen Mengen  $\{\omega\}$  von  $\Omega$  heißen Elementarereignisse

---

### 7.3.2 Wahrscheinlichkeit

---

**Definition 7.3.4** Ein System  $\mathcal{A} \subseteq \mathcal{P}(\Omega)$  von Ereignissen heißt  $\sigma$ -Algebra (oder Ereignissystem) wenn gilt:

- $\Omega \in \mathcal{A}$
- Falls  $A \in \mathcal{A}$ , dann auch  $A^c \in \mathcal{A}$
- mit jeder Folge  $A_1, A_2, \dots \in \mathcal{A}$  gilt auch  $\bigcup_{i=1}^{\infty} A_i \in \mathcal{A}$

**Definition 7.3.6** Eine Abbildung  $P : \mathcal{A} \rightarrow \mathbb{R}$  heißt Wahrscheinlichkeitsmaß, wenn sie folgenden Axiomen von Komogorov genügt:

- $P(A) \geq 0$  für  $A \in \mathcal{A}$
- $P(\Omega) = 1$
- $P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_i 1^\infty P(A_i)$  für paarweise unvereinbare  $A_1, A_2, \dots \in \mathcal{A}$

Für beliebige Ereignisse  $A \subseteq \Omega$  mit Elementzahl  $\# A$  gilt

$$P(A) = \frac{\text{Elementzahl von } A}{n} = \frac{\# A}{\# \Omega}$$

---

### 7.3.3 Elementare Formeln der Kombinatorik

---

#### Geordnete Probe mit Wiederholungen

$$n^k$$

Bsp: k mal würfeln

#### Geordnete Probe ohne Wiederholungen

$$n(n-1)(n-2)\dots(n-k+1)$$

Bsp: k autos parken auf n Parkplätzen

Im Falle  $k = n$  **Permutation der Menge**  $\Omega$

$$n!$$

#### Ungeordnete Probe ohne Wiederholungen

$$\binom{n}{k} = \frac{n!}{k!(n-k)!} \quad (4)$$

Bsp: Lotto

---

## 7.4 Bedingte Wahrscheinlichkeit, Unabhängigkeiten

---

### 7.4.1 Bedingte Wahrscheinlichkeit

---

#### Bedingte Wahrscheinlichkeit von A unter der Bedingung B

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

#### Regel von der vollständigen Wahrscheinlichkeit

$$P(B) = \sum_{i=1}^n P(A_i)P(B|A_i)$$

#### Formel von Bayes

$$P(A_i|B) = \frac{P(A_i)P(B|A_i)}{\sum_{k=1}^n P(A_k)P(B|A_k)}$$

#### Multiplikationsformel

$$P(A_1 \cap A_2 \cap \dots \cap A_n) = P(A_1)P(A_2|A_1)P(A_3|A_1 \cap A_2) \dots P(A_n|A_1 \cap \dots \cap A_{n-1})$$

---

### 7.4.2 Unabhängigkeit

---

**Definition 7.4.3** Zwei Ereignisse A und B heißen unabhängig, falls

$$P(A \cap B) = P(A)P(B)$$

Ereignisse  $A_1, \dots, A_n$  heißen vollständig unabhängig, falls für alle  $\{i_1, \dots, i_k\} \subseteq \{1, \dots, n\}$  gilt

$$P(A_{i_1} \cap \dots \cap A_{i_k}) = P(A_{i_1}) \cdot \dots \cdot P(A_{i_k})$$

---

## 7.5 Zufallsvariablen und Verteilungsfunktion

---

**Definition 7.5.1** Eine Zufallsvariable ist eine Abbildung

$$x : \Omega \rightarrow \mathbb{R}$$

mit der Eigenschaft, dass für jedes Intervall  $I \subseteq \mathbb{R}$  die Urbildmenge

$$A = \{\omega \in \Omega : X(\omega) \in I\}$$

zum Ereignissystem  $\mathcal{A}$  gehört. Die Wahrscheinlichkeit dieses Ereignisses "X nimmt Werte im Intervall I an" bezeichnet man abkürzend mit  $P(X \in I)$  und schreibt

$$P(A \leq X \leq B), P(X \leq x),$$

$$P(|X - a| < b), P(X = b),$$

usw

---

**Definition 7.5.3** Sei  $X : \Omega \rightarrow \mathbb{R}$  eine Zufallsvariable. Die Abbildung  $F : \mathbb{R} \rightarrow \mathbb{R}$

$$F(x) = P(X \leq x), x \in \mathbb{R}$$

heißt Verteilungsfunktion der Zufallsvariable  $X$

Verteilungsfunktionen sind monoton wachsende Funktionen mit

$$F(-\infty) = 0$$

$$F(\infty) = 1$$

$$F(x+) = F(x)$$

$$\forall x \in \mathbb{R}$$

Zudem:

$$P(X = a) = F(a) - F(a-)$$

$$P(a < X \leq b) = F(b) - F(a)$$

$$P(a \leq X < b) = F(b-) - F(a-)$$

$$P(a \leq X \leq b) = F(b) - F(a-)$$

$$P(x > a) = 1 - F(a)$$

Eine Zufallsvariable heißt stetig verteilt mit der Dichte  $f$  wenn ihre Verteilungsfunktion  $F$  durch

$$F(x) = \int_{-\infty}^x f(t) dt, x \in \mathbb{R}$$

gegeben ist.

---

### 7.5.1 Beispiele für diskrete Verteilungen

---

#### Geometrische Verteilung

---

Es sei  $0 < p < 1$  eine Zufallsvariable  $X$  mit dem Wertebereich  $\mathbb{N}$  heißt geometrisch verteilt mit dem Parameter  $p$  falls

$$P(X = i) = (1 - p)^{i-1} p, i = 1, 2, \dots$$

#### Anwendung:

Wird ein Zufallsexperiment, bei dem ein bestimmtes Ereignis mit Wahrscheinlichkeit  $p$  eintritt, so lange unabhängig wiederholt, bis zum ersten Mal dieses Ereignis eintritt, dann kann die Anzahl der dazu benötigten Versuche durch eine geometrisch verteilte Zufallsvariable modelliert werden („Warten auf den ersten Erfolg“).

---

#### Binominalverteilung

---

Sei  $n \in \mathbb{N}$  und  $0 < p < 1$ . Eine Zufallsvariable  $X$  mit dem Wertebereich  $\mathbb{N}_0 = \{0, 1, 2, \dots\}$  heißt binominalverteilt mit Parametern  $n$  und  $p$ , kurz  $B(n, p)$ -verteilt falls

$$P(X = i) = \binom{n}{i} p^i (1 - p)^{n-i}, i = 0, 1, 2, \dots, n$$

#### Anwendung:

Wird ein Zufallsexperiment, bei dem ein bestimmtes Ereignis mit Wahrscheinlichkeit  $p$  eintritt,  $n$ -mal unabhängig wiederholt, und dabei gezählt, wie oft dieses Ereignis eintritt, so kann diese zufällige Anzahl als  $B(n, p)$ -verteilte Zufallsvariable  $X$  beschrieben werden („Anzahl der Erfolge bei  $n$  Versuchen“).

---

#### Poissonverteilung

---

Sei  $\lambda > 0$ . Eine Zufallsvariable  $X$  mit dem Wertebereich  $\mathbb{N}_0$  heißt Poisson-verteilt falls gilt

$$P(X = i) = \frac{\lambda^i}{i!} e^{-\lambda}, i = 0, 1, 2, \dots$$

Sie eignet sich zur Modellierung von Zählergebnissen folgenden Typs: In einer Telefonzentrale wird die Anzahl der innerhalb von 10 Minuten eingehenden Anrufe gezählt.  $\lambda$  gibt die „mittlere Anzahl“ der eingehenden Anrufe an.

$$E(X) = \lambda$$

---

## 7.5.2 Beispiele für Stetige Verteilungen

---

### Rechteckverteilung

---

Es sei  $a < b$ . Eine Stetig verteilte Zufallsvariable mit der Dichte

$$f(t) = \begin{cases} \frac{1}{b-a}, & a \leq t \leq b \\ 0 & \text{sonst} \end{cases}$$

heißt rechteckverteilt im Intervall  $[a, b]$ , kurz  $R(a, b)$ -verteilt. Für die Verteilungsfunktion ergibt sich

$$F(x) = \int_{-\infty}^x f(t)dt = \begin{cases} 0, & x \leq a \\ \frac{x-a}{b-a}, & a < x < b \\ 1, & x \geq b \end{cases}$$

---

### Exponentialverteilung

---

Sei  $\lambda > 0$ . Eine Stetig verteilte Zufallsvariable  $X$  mit der Dichte

$$f(t) = \begin{cases} 0, & t < 0 \\ \lambda e^{-\lambda t}, & t \geq 0 \end{cases}$$

heißt exponentialverteilt mit Parameter  $\lambda$ , kurz  $Ex(\lambda)$ . Für die Verteilungsfunktion ergibt sich

$$F(x) = \int_{-\infty}^x f(t)dt = \begin{cases} 0, & x < 0 \\ 1 - e^{-\lambda x}, & x \geq 0 \end{cases}$$

$$E(X) = \frac{1}{\lambda}$$

---

### Normalverteilung

---

Es seien  $\mu \in \mathbb{R}$  (Erwartungswert) und  $\sigma > 0$  (Varianz). Eine Stetig verteilte Zufallsvariable mit der Dichte

$$f(t) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{t-\mu}{\sigma}\right)^2}, t \in \mathbb{R}$$

heißt normalverteilt mit Parameter  $\mu$  und  $\sigma^2$  kurz:  $N(\mu, \sigma^2)$ . Im Falle  $\mu = 0, \sigma^2 = 1$  spricht man von einer Standard-Normalverteilung mit der Verteilungsfunktion

$$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-t^2/2}, x \geq 0$$

(Kann aus Tabelle Entnommen werden)

Es gilt:

$$\Phi(0) = \frac{1}{2}, \quad \Phi(-x) = 1 - \Phi(x) \quad x \geq 0$$

Allgemein ist die Verteilungsfunktion

$$F_{\mu, \sigma^2}(x) = \Phi\left(\frac{x-\mu}{\sigma}\right)$$

---

## 7.6 Erwartungswert und Varianz

---

Ist  $X$  eine Diskret verteilte Zufallsvariable mit Werten  $x_1, x_2, \dots$  so heißt

$$E(X) = \sum_i x_i P(X = x_i)$$

Erwartungswert von  $X$  falls  $\sum_i |x_i| P(X = x_i) < \infty$

Ist  $X$  eine stetig verteilte Zufallsvariable mit Dichte  $f$  so heißt

$$E(X) = \int_{-\infty}^{\infty} x f(x) dx$$

Erwartungswert von  $X$ , falls  $\int_{-\infty}^{\infty} |x|f(x)dx < \infty$

Ist  $h : \mathbb{R} \rightarrow \mathbb{R}$  eine Stückweise stetige Funktion dann hat die Zufallsvariable  $h(X)$  für eine diskret verteilte Zufallsvariable  $X$  den Erwartungswert

$$E(h(X)) = E(X) = \sum_i h(x_i)P(X = x_i)$$

Ist  $X$  stetig verteilt mit Dichte  $f$  dann hat  $h(X)$  den Erwartungswert

$$E(h(X)) = \int_{-\infty}^{\infty} h(x)f(x)dx$$

Der Erwartungswert der quadratischen Abweichung der Zufallsvariablen  $X$  zu  $E(X)$  heißt Varianz von  $X$

$$Var(X) = E([X - E(X)]^2) = E(X^2) - (E(X))^2$$

Die Standardabweichung ist definiert durch  $\sqrt{Var(X)}$

### 7.6.1 Rechenregeln

Es gilt

$$\begin{aligned} E(aX + b) &= aE(X) + b \\ E(h_1(X) + h_2(X)) &= E(h_1(X)) + E(h_2(X)) \end{aligned}$$

für Eine Zufallsvariable  $X, a, b \in \mathbb{R}$  und  $h_1, h_2$  stückweise Stetige Funktionen

Allgemeiner gilt für Zufallsvariablen  $X_1, \dots, X_n$  und  $a_1, \dots, a_n, b \in \mathbb{R}$ :

$$E(a_1X_1 + \dots + a_nX_n + b) = a_1E(X_1) + \dots + a_nE(X_n) + b$$

Der Erwartungswert ist also linear

Weiterhin gilt

$$Var(aX + b) = a^2 Var(X)$$

Verteilung	$E(X)$	$Var(X)$
$N(\mu, \sigma^2)$	$\mu$	$\sigma^2$
$Ex(\lambda)$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
$B(n, p)$	$np$	$np(1-p)$
Geom	$\frac{1}{p}$	$\frac{1-p}{p^2}$
Poisson	$\lambda$	$\lambda$
Rechteck	$\frac{a+b}{2}$	$\frac{1}{12}(b-a)$

### Tschebyschevsche Ungleichung

Es gilt

$$P(|X - E(X)| \geq c) \leq \frac{Var(X)}{c^2}, c > 0$$

**Definition 7.6.3** (Unabhängigkeit) Seien  $X_1, X_2, \dots, X_n$  Zufallsvariablen mit Verteilungsfunktionen  $F_1, F_2, \dots, F_n$  die gemeinsame Verteilungsfunktion von  $X_1, X_2, \dots, X_n$  ist definiert durch

$$F(x_1, x_2, \dots, x_n) = P(X_1 \leq x_1, \dots, X_n \leq x_n), (x_1, \dots, x_n) \in \mathbb{R}^n$$

Die Zufallsvariablen heißen unabhängig, wenn für alle  $(x_1, \dots, x_n) \in \mathbb{R}^n$  die Ereignisse

$$\{X_1 \leq x_1\}, \dots, \{X_n \leq x_n\}$$

vollständig unabhängig sind, also

$$P(X_1 \leq x_1, \dots, X_n \leq x_n) = P(X_1 \leq x_1) \dots P(X_n \leq x_n)$$

oder kurz

$$F(x_1, \dots, x_n) = F_1(x_1) \dots F_n(x_n)$$

**Satz 7.6.4** Die Zufallsvariablen  $X_1, X_2, \dots, X_n$  seien unabhängig. Es gilt

$$Var(X_1 + \dots + X_n) = Var(X_1) + \dots + Var(X_n)$$

---

## 7.7 Gesetz der großen Zahlen, zentraler Grenzwertsatz

---

### 7.7.1 Das schwache gesetz der großen Zahlen

---

**Satz 7.7.1** Ist  $X_1, X_2, \dots$  eine Folge unabhängiger identisch verteilter Zufallsvariablen mit  $E(X_i) = \mu$ ,  $Var(X_i) = \sigma^2$  dann gilt

$$\lim_{n \rightarrow \infty} P \left( \left| \frac{1}{n} \sum_{i=1}^n X_i - \mu \right| \geq \epsilon \right) = 0, \quad \forall \epsilon > 0$$

---

### 7.7.2 Zentraler Grenzwertsatz

---

**Satz 7.7.2** Ist  $X_1, X_2, \dots$  eine Folge unabhängiger Zufallsvariablen mit

$$E(X_i) = \mu_i \qquad Var(X_i) = \sigma_i^2 \qquad i = 1, 2, \dots$$

so gilt unter schwachen zusätzlichen Voraussetzungen, z.B dass die  $X_i$  identisch verteilt sind:

$$\lim_{n \rightarrow \infty} P \left( \frac{X_1 + \dots + X_n - (\mu_1 + \dots + \mu_n)}{\sqrt{\sigma_1^2 + \dots + \sigma_n^2}} \leq y \right) = \Phi(y) \quad \forall y \in \mathbb{R}$$

Ein Arimetisches Mittel  $\bar{X}_{(n)}$  ist für großes  $n$  also Näherungsweise  $N(\mu, \sigma^2)$  verteilt, wobei

$$\mu = \frac{1}{n} E(X_1 + \dots + X_n) = \frac{1}{n} (\mu_1 + \dots + \mu_n) \qquad \sigma^2 = \frac{1}{n^2} Var(X_1 + \dots + X_n) = \frac{1}{n^2} (\sigma_1^2 + \dots + \sigma_n^2)$$

---

## Wahrscheinlichkeitstheoretisches Modell für Messreihen

---

Empirische Verteilungsfunktion

$$F_n(z; x_1, x_2, \dots, x_n) = \frac{\text{Zahl der } x_i \text{ mit } x_i \leq z}{n}$$

**Satz 7.7.4** (Zentralsatz der Statistik) Sei  $X_1, X_2, \dots$  eine Folge unabhängiger identisch verteilter Zufallsvariablen mit der Verteilungsfunktion  $F$  und bezeichne

$$D_n(X_1, \dots, X_n) = \sup_{z \in \mathbb{R}} |F_n(z; X_1, \dots, X_n) - F(z)|$$

die Zufällige Maximalabweichung zwischen empirischer und

wahrer

Verteilungsfunktion, Dann gilt

$$P \left( \lim_{n \rightarrow \infty} D_n(X_1, \dots, X_n) = 0 \right) = 1$$

$D_n(X_1, \dots, X_n)$  konvergiert also mit Wahrscheinlichkeit 1 gegen 0

---

## 7.8 Testverteilungen und Quantilapproximationen

---

Seien  $Z_1, \dots, Z_n$  unabhängige identisch  $N(0,1)$ -Verteilte Zufallsgrößen.

**$\chi_r^2$ -Verteilung:**

Es sei  $r \in \{1, \dots, n\}$ . Eine Zufallsvariable  $X$  heißt  $\chi_r^2$ -verteilt, falls sie die Verteilungsfunktion

$$F(x) = P(Z_1^2 + \dots + Z_r^2 \leq x), \quad x \in \mathbb{R}$$

besitzt

**$t_r$ -Verteilung:**

es sei  $r \in \{1, \dots, n-1\}$ . Eine Zufallsvariable  $X$  heißt  $t_r$ -verteilt, falls sie die Verteilungsfunktion

$$F(x) = P \left( \frac{Z_{r+1}}{\sqrt{(Z_1^2 + \dots + Z_r^2)/r}} \leq x \right), \quad x \in \mathbb{R}$$

besitzt



### **F<sub>r,s</sub>-Verteilung**

Es sei  $r, s \in \{1, \dots, n-1\}$  mit  $r+s \leq n$ . Eine Zufallsvariable  $X$  heißt F-verteilt mit  $r$  und  $s$  Freiheitsgraden, falls sie die Verteilungsfunktion

$$F(x) = P\left(\frac{(Z_1^2 + \dots + Z_r^2)/r}{(Z_{r+1}^2 + \dots + Z_{r+s}^2)/s} \leq x\right), x \in \mathbb{R}$$

besitzt

Die Dichte dieser Verteilungen können unter Verwendung der Gamma-Funktion

$$\Gamma(x) = \int_0^\infty e^{-t} t^{x-1} dt, x > 0$$

und der Beta-Funktion

$$B(\alpha, \beta) = \int_0^1 t^{\alpha-1} (1-t)^{\beta-1} dt, \alpha, \beta > 0$$

(Don't ask me how)

### **Bezeichnungen für Quantile**

Allgemein  $F(x_p) = p$ .

$u_p$	p-Quantil der $N(0,1)$ -Verteilung
$t_{r;p}$	p-Quantil der $t_r$ -Verteilung
$\chi_{r;p}^2$	p-Quantil der $\chi_r^2$ -Verteilung
$F_{r,s;p}$	p-Quantil der $F_{r,s}$ -Verteilung

---

## **7.8.1 Wichtige Anwendungsbeispiele**

---

**Satz 7.8.1** Es seien  $X_1, \dots, X_n$  unabhängige, identisch  $N(\mu, \sigma^2)$ -verteilte Zufallsvariable. Dann gilt

- $\bar{X}_{(n)}$  ist  $N(\mu, \sigma^2/n)$ -verteilt
- $\frac{n-1}{\sigma^2} S_{(n)}^2$  ist  $\chi_{n-1}^2$ -verteilt
- $\bar{X}_{(n)}$  und  $S_{(n)}^2$  sind unabhängig
- $\sqrt{n} \frac{\bar{X}_{(n)} - \mu}{\sqrt{S_{(n)}^2}}$  ist  $t_{n-1}$ -verteilt

---

## 8 Schätzverfahren und Konfidenzintervalle

---

### 8.1 Grundlagen zu Schätzverfahren

---

**Definition 8.1.2** Ein Schätzverfahren oder eine Schätzfunktion oder kurz Schätzer ist eine Abbildung

$$T_n : \mathbb{R}^n \rightarrow \mathbb{R}$$

Sie ordnet einer Messreihe  $x_1, \dots, x_n$  einen Schätzwert  $T_n(x_1, \dots, x_n)$  (Zufallsvariable) für den unbekannten Wert  $\tau(\theta)$  zu. Die Zufallsvariable  $T_n(X_1, \dots, X_n)$  heißt Schätzvariable.

**Definition 8.1.3** ein Schätzer  $T_n : \mathbb{R}^n \rightarrow \mathbb{R}$  heißt erwartungstreu für  $\tau : \Theta \rightarrow \mathbb{R}$ , falls gilt

$$E_\theta(T_n(X_1, \dots, X_n)) = \tau(\theta) \text{ für alle } \theta \in \Theta$$

**Definition 8.1.4** •  $\tau$  sei gegeben durch  $\tau(\theta) = E_\theta(X) = \mu$ . Das arithmetische Mittel  $\bar{X}_{(n)}$  ist ein erwartungstreuer Schätzer für  $\mu$

•  $\tau$  sei gegeben durch  $\tau(\theta) = \text{Var}_\theta(X) = \sigma^2$ . Die Stichprobenvarianz  $S_{(n)}^2$  ist ein erwartungstreuer Schätzer für  $\sigma^2$

**Definition 8.1.5** Eine Folge von Schätzern  $T_n : \mathbb{R}^n \rightarrow \mathbb{R}$ ,  $n = 1, 2, \dots$  heißt asymptotisch erwartungstreu für  $\tau$  falls gilt

$$\lim_{n \rightarrow \infty} E_\theta(T_n(X_1, \dots, X_n)) = \tau(\theta) \text{ für alle } \theta \in \Theta$$

**Mittlerer quadratischer Fehler (mean squared error):**

$$MSE_\theta(T) := E_\theta((T - \tau(\theta))^2)$$

Es gilt

$$T \text{ erwartungstreu} \Rightarrow MSE_\theta(T) = \text{Var}_\theta(T)$$

$T_1$  ist effizienter als  $T_2$  wenn gilt

$$MSE_\theta(T_1) \leq MSE_\theta(T_2)$$

**Definition 8.1.6** Eine Folge von Schätzern  $T_1, T_2, \dots$  heißt konsistent für  $\tau$  wenn für alle  $\varepsilon > 0$  und alle  $\theta \in \Theta$  gilt

$$\lim_{n \rightarrow \infty} P_\theta(|T_n(X_1, \dots, X_n) - \tau(\theta)| > \varepsilon) = 0$$

Sie heißt konsistent im quadratischen Mittel für  $\tau$  wenn für alle  $\theta \in \Theta$  gilt

$$\lim_{n \rightarrow \infty} MSE_\theta(T_n) = 0$$

**Satz 8.1.7** Ist  $T_1, T_2, \dots$  eine Folge von Schätzern, die erwartungstreu für  $\tau$  sind und gilt

$$\lim_{n \rightarrow \infty} \text{Var}_\theta(T_n(X_1, \dots, X_n)) = 0 \text{ für alle } \theta \in \Theta$$

dann ist die Folge von Schätzern konsistent für  $\tau$

**Satz 8.1.8** Ist  $T_1, T_2, \dots$  eine Folge von Schätzern, die konsistent im quadratischen Mittel für  $\tau$  ist, dann ist die Folge von Schätzern konsistent für  $\tau$

---

### 8.2 Maximum-Likelihood-Schätzer

---

Bei gegebener Verteilungsklasse  $F_\theta, \theta \in \Theta$ , lassen sich Schätzer für den Parameter  $\theta$  oft mit der Maximum-Likelihood-Methode gewinnen. Sind die zugrundeliegenden Zufallsvariablen  $X_1, \dots, X_n$  stetig mit einer Dichte verteilt, so hängt diese ebenfalls von den Parametern ab:

$$f_\theta(x), x \in \mathbb{R}.$$

Wir definieren hier  $\mathbb{X} = \mathbb{R}$ . Im Fall diskreter Zufallsvariablen  $X$ , bzw.  $X_1, \dots, X_n$  definieren wir

$$f_\theta(x) = P_\theta(X = x) \text{ für alle } x \text{ aus dem Wertebereich } \mathbb{X} \text{ von } X.$$

---

**Definition 8.2.1** Für eine Messreihe  $x_1, \dots, x_n$  heißt die Funktion  $L(\cdot; x_1, \dots, x_n)$  mit

$$L(\theta; x_1, \dots, x_n) = f_\theta(x_1)f_\theta(x_2) \dots f_\theta(x_n)$$

die zu  $x_1, \dots, x_n$  gehörige Likelihood-Funktion

Ein Parameterwert

$$\hat{\theta} = \hat{\theta}(x_1, \dots, x_n)$$

mit

$$L(\hat{\theta}; x_1, \dots, x_n) \geq L(\theta; x_1, \dots, x_n) \text{ für alle } \theta \in \Theta$$

heißt Maximum-Likelihood-Schätzwert für  $\Theta$ . Existiert dieser zu jeder möglichen Messreihe, dann heißt

$$T_n : \mathbb{X}^n \rightarrow \Theta, T_n(x_1, \dots, x_n) = \hat{\theta}(x_1, \dots, x_n)$$

Maximum-Likelihood-Schätzern

---

### 8.3 Konfidenzintervalle

---

**Definition 8.3.1** Sei  $0 < \alpha < 1$ . Das zufällige Intervall  $I(X_1, \dots, X_n)$  heißt Konfidenzintervall für  $\tau(\theta)$  zum Konfidenzniveau  $1 - \alpha$ , falls gilt

$$P_\theta(U(X_1, \dots, X_n) \leq \tau(\theta) \leq O(X_1, \dots, X_n)) \geq 1 - \alpha \text{ für alle } \theta \in \Theta$$

Das zu einer bestimmten Messreihe  $x_1, \dots, x_n$  gehörige Intervall

$$I(x_1, \dots, x_n) = [U(X_1, \dots, X_n), O(X_1, \dots, X_n)]$$

heißt konkretes Schätzintervall für  $\tau(\Theta)$

---

#### 8.3.1 Konstruktion von Konfidenzintervallen

---

Im Folgenden

$$F_\theta(x) = F_{(\mu, \sigma^2)}(x) = \Phi\left(\frac{x - \mu}{\sigma}\right)$$

$$\bar{X}_{(n)} = \frac{1}{n} \sum_{i=1}^n X_i$$

$$S_{(n)}^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_{(n)})^2$$

Konfidenzintervalle zum Niveau  $1 - \alpha$ :

---

##### Konfidenzintervall für $\mu$ bei bekannter Varianz $\sigma^2 = \sigma_0^2$

---

Hier ist  $\Theta = \{(\mu, \sigma_0^2) : \mu \in \mathbb{R}\}$  und  $\tau(\theta) = \mu$ . Das Konfidenzintervall für  $\mu$  zum Niveau  $1 - \alpha$  lautet

$$I(X_1, \dots, X_n) = \left[ \bar{X}_{(n)} - u_{1-\alpha/2} \frac{\sigma_0}{\sqrt{n}}, \bar{X}_{(n)} + u_{1-\alpha/2} \frac{\sigma_0}{\sqrt{n}} \right]$$

---

##### Konfidenzintervall für $\mu$ bei unbekannter Varianz $\sigma^2$

---

Hier ist  $\Theta = \{(\mu, \sigma_0^2) : \mu \in \mathbb{R}, \sigma^2 > 0\}$  und  $\tau(\theta) = \mu$ . Das Konfidenzintervall für  $\mu$  lautet

$$I(X_1, \dots, X_n) = \left[ \bar{X}_{(n)} - t_{n-1; 1-\alpha/2} \sqrt{\frac{S_{(n)}^2}{n}}, \bar{X}_{(n)} + t_{n-1; 1-\alpha/2} \sqrt{\frac{S_{(n)}^2}{n}} \right]$$

---

##### Konfidenzintervall für $\sigma^2$ bei bekanntem Erwartungswert $\mu = \mu_0$

---

Hier ist  $\Theta = \{(\mu, \sigma_0^2) : \sigma^2 > 0\}$  und  $\tau(\theta) = \sigma^2$ . Das Konfidenzintervall für  $\sigma^2$  lautet

$$I(X_1, \dots, X_n) = \left[ \frac{\sum_{i=1}^n (X_i - \mu_0)^2}{\chi_{n-1; 1-\alpha/2}^2}, \frac{\sum_{i=1}^n (X_i - \mu_0)^2}{\chi_{n-1; \alpha/2}^2} \right]$$

---

##### Konfidenzintervall für $\sigma^2$ bei unbekanntem Erwartungswert $\mu$

---

Hier ist  $\Theta = \{(\mu, \sigma_0^2) : \mu \in \mathbb{R}, \sigma^2 > 0\}$  und  $\tau(\theta) = \sigma^2$ . Das Konfidenzintervall für  $\sigma^2$  lautet

$$I(X_1, \dots, X_n) = \left[ \frac{(n-1)S_{(n)}^2}{\chi_{n-1; 1-\alpha/2}^2}, \frac{(n-1)S_{(n)}^2}{\chi_{n-1; \alpha/2}^2} \right]$$

---

## 9 Tests bei Normalverteilungsannahmen

---

### 9.1 Grundlagen

---

#### Konstruktionsprinzip für Test zum Niveau $\alpha$

---

Tests lassen sich nach dem folgenden allgemeinen Prinzip konstruieren

1. Verteilungsannahme formulieren
2. Nullhypothese  $H_0$  formulieren
3. Testgröße  $T$  wählen und ihre Verteilung unter  $H_0$  bestimmen
4.  $I \subseteq \mathbb{R}$  so wählen, dass unter  $H_0$  gilt  $P(T(X_1, \dots, X_n) \in I) \leq \alpha$

---

### 9.2 Wichtige Tests bei Normalverteilungsannahme

---

#### Gauß-Test

---

1.  $X_1, \dots, X_n$  unabhängig, identisch  $N(\mu, \sigma_0^2)$ -verteilt  $\sigma_0^2$  bekannt
2. a)  $H_0 : \mu = \mu_0$ , b)  $H_0 : \mu \leq \mu_0$ , c)  $H_0 : \mu \geq \mu_0$
3. Testgröße

$$T(X_1, \dots, X_n) = \frac{\sqrt{n}}{\sigma_0} (\bar{X}_{(n)} - \mu_0)$$

4. Ablehnung Falls
  - a)  $|T| > u_{1-\alpha/2}$ , b)  $T > u_{1-\alpha}$ , c)  $T < u_\alpha$

---

#### t-Test

---

1.  $X_1, \dots, X_n$  unabhängig, identisch  $N(\mu, \sigma^2)$ -verteilt  $\sigma^2$  unbekannt
2. a)  $H_0 : \mu = \mu_0$ , b)  $H_0 : \mu \leq \mu_0$ , c)  $H_0 : \mu \geq \mu_0$
3. Testgröße

$$T(X_1, \dots, X_n) = \sqrt{n} \frac{\bar{X}_{(n)} - \mu_0}{\sqrt{S_{(n)}^2}}$$

4. Ablehnung Falls
  - a)  $|T| > t_{n-1; 1-\alpha/2}$ , b)  $T > t_{n-1; 1-\alpha}$ , c)  $T < t_{n-1; \alpha}$

---

#### $\chi^2$ -Streuungstest

---

1.  $X_1, \dots, X_n$  unabhängig, identisch  $N(\mu, \sigma^2)$ -verteilt  $\mu, \sigma^2$  unbekannt
2. a)  $H_0 : \sigma^2 = \sigma_0^2$ , b)  $H_0 : \sigma^2 \leq \sigma_0^2$ , c)  $H_0 : \sigma^2 \geq \sigma_0^2$
3. Testgröße

$$T(X_1, \dots, X_n) = \frac{(n-1)}{\sigma_0^2} S_{(n)}^2$$

4. Ablehnung falls
  - a)  $T < \chi_{n-1; \alpha/2}^2$  oder  $T > \chi_{n-1; 1-\alpha/2}^2$ , b)  $T > \chi_{n-1; 1-\alpha}^2$ , c)  $T < \chi_{n-1; \alpha}^2$

---

### 9.3 Verteilungstests

---

Könnt ich auch nicht kürzer zusammenfassen, einfach im Skript schauen